

OUTLINE KHÓA LUẬN TỐT NGHIỆP

Đề tài: Nghiên cứu, xây dựng hệ thống tóm tắt và kiểm chứng tin tức tiếng Việt sử dụng mô hình ngôn ngữ lớn.

Sinh viên: Lê Văn Thắng — 22028313

Cán bộ hướng dẫn: TS. Vương Thị Hồng

Cập nhật: 05/2026 (phản ánh hệ thống hoàn chỉnh)

MỤC LỤC DỰ KIẾN

Trang bìa · Trang phụ bìa (VI/EN) · Tóm tắt · Abstract · Lời cam đoan · Mục lục
· Danh mục hình · Danh mục bảng · Bảng ký hiệu viết tắt

MỞ ĐẦU

Tính cấp thiết

Sự bùng nổ thông tin trực tuyến tiếng Việt đặt ra hai thách thức song song: người dùng cần tóm tắt nhanh nội dung bài báo và cần công cụ kiểm chứng độ chính xác. Các hệ thống tóm tắt đơn mô hình còn hạn chế; kỹ thuật Mixture-of-Agents (MoA) — kết hợp nhiều LLM để tổng hợp đầu ra — chưa được nghiên cứu cho tiếng Việt. Đồng thời, các metric đánh giá truyền thống (ROUGE/BLEU/BERTScore) đo độ trùng lặp với văn bản gốc, không phản ánh chính xác chất lượng tóm tắt theo tiêu chí người dùng.

Ý nghĩa khoa học và thực tiễn

Về mặt khoa học, đề tài đóng góp một framework đánh giá ba trục (Axis A/B/C) cho bài toán tóm tắt văn bản, chỉ ra giới hạn của overlap metrics (ROUGE/BLEU/BERTScore) khi áp dụng cho hệ thống tổng hợp đa mô hình; đây là vấn đề chưa được làm rõ trong văn học khoa học tiếng Việt. Về mặt thực tiễn, hệ thống tiện ích trình duyệt được xây dựng có thể triển khai trực tiếp phục vụ người dùng Việt Nam trong việc đọc, tóm tắt và kiểm chứng thông tin từ các trang báo điện tử.

Mục tiêu nghiên cứu

1. Xây dựng hệ thống tiện ích trình duyệt tích hợp tóm tắt + kiểm chứng tin tức tiếng Việt.
2. Triển khai pipeline MoA (Wang et al., 2024) cho tóm tắt tiếng Việt.
3. Xây dựng framework đánh giá ba trục (Axis A/B/C) để kiểm chứng thực nghiệm MoA, làm rõ giới hạn của overlap metrics.

Đối tượng & phạm vi

Bài báo tiếng Việt từ các trang: tuoitre.vn, thanhnien.vn, tienphong.vn, vietnamnet.vn, vtv.vn; 5 chủ đề: thời sự, pháp luật, kinh tế, giáo dục, văn hóa.

Phương pháp nghiên cứu

Thực nghiệm so sánh đa mô hình; đánh giá tự động (ROUGE/BLEU/BERTScore — Axis A), đánh giá bởi LLM-judge (pairwise AlpacaEval-style — Axis B), và đánh giá con người mù (blind human ranking — Axis C); kiểm định thống kê (sign test, Fleiss κ).

Nội dung nghiên cứu

Khóa luận được tổ chức thành 4 chương: Chương 1 trình bày tổng quan các bài toán và công trình liên quan; Chương 2 trình bày cơ sở lý thuyết về LLM, các phương pháp đánh giá và các công nghệ nền tảng sử dụng trong hệ thống; Chương 3 trình bày thiết kế và xây dựng hệ thống bao gồm pipeline MoA, module kiểm chứng và framework đánh giá ba trục; Chương 4 trình bày thiết lập thực nghiệm, kết quả đánh giá theo ba trục và thảo luận.

CHƯƠNG 1. TỔNG QUAN

1.1. Bài toán tóm tắt văn bản tự động

Định nghĩa; phân loại extractive vs. abstractive, single vs. multi-document; tóm tắt tiếng Việt — thách thức đặc thù (từ ghép đa âm tiết, thiếu benchmark corpus).

1.2. Bài toán kiểm chứng tin tức

Tin giả và misinformation trong bối cảnh Việt Nam; pipeline kiểm chứng tự động: claim detection → evidence retrieval → verdict prediction; hướng search-augmented verification.

1.3. Mixture-of-Agents (MoA)

Tổng quan Wang et al. (2024): kiến trúc proposer–aggregator hai tầng; nguyên lý "model làm aggregator hoạt động tốt hơn khi được cung cấp nhiều draft từ các model khác"; kết quả gốc trên AlpacaEval 2.0 (win rate 65.1%); câu hỏi mở về transfer sang grounded summarization.

1.4. Các công trình liên quan

Hệ thống tóm tắt: Google News, BáoMới; tools fact-check: ClaimBuster, Google Fact Check Tools; browser extensions: TLDR, Newsguard. Khoảng trống: chưa có giải pháp tích hợp MoA cho tiếng Việt với framework đánh giá đa trục.

1.5. Tổng kết chương

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Mô hình ngôn ngữ lớn

- **2.1.1.** Kiến trúc Transformer (Vaswani et al., 2017): self-attention, multi-head, encoder-decoder.
- **2.1.2.** Các dòng mô hình: encoder-only (BERT), decoder-only (GPT), encoder-decoder (T5).
- **2.1.3.** Các mô hình trong hệ thống: GPT-4o (aggregator), GPT-4o-mini / Claude Haiku 4.5 / Gemini 2.5 Flash (proposers), ViT5-large (routing), PhoBERT (BERTScore).

2.2. Metrics đánh giá tóm tắt (Axis A)

- **2.2.1.** ROUGE-1/2/L: công thức precision/recall/F1, ưu nhược điểm với tiếng Việt.
- **2.2.2.** BLEU: modified n-gram precision + brevity penalty.
- **2.2.3.** BERTScore với PhoBERT (vinai/phobert-base): cosine similarity giữa contextual embeddings; ưu điểm ngữ nghĩa so với lexical metrics.
- **2.2.4.** Compression Rate: tỷ lệ nén token; trade-off giữa nén cao và mất thông tin.

- **2.2.5.** Giới hạn phương pháp: các metric trên đo content retention từ nguồn, không đo summary quality — caveat cốt lõi của khóa luận.

2.3. LLM-as-Judge methodology (Axis B)

- **2.3.1.** Rubric evaluation (FLASK-derived): 5 chiều: faithfulness, coverage, fluency, conciseness, overall; thang 1–5; Vietnamese journalism prompt.
- **2.3.2.** Absolute scoring (MT-Bench style): điểm holistic 1–10.
- **2.3.3.** Pairwise preference (AlpacaEval style): A vs B; position randomization để kiểm soát position bias; sign test p-value.
- **2.3.4.** Length-bucketed win rate (Dubois 2024): kiểm soát length bias; 3 bucket (<0.85 , $0.85\text{--}1.15$, >1.15).

2.4. Đánh giá factuality

Claim splitting → entailment classification (entailed / contradicted / not_mentioned) qua gpt-4o-mini; hallucination counting.

2.5. Human evaluation & inter-rater agreement (Axis C)

Blind K-way ranking; Fleiss κ ($\kappa \geq 0.4$ = moderate agreement, ngưỡng publishable); per-approach average rank và win rate.

2.6. Content extraction

Mozilla Readability + JSDOM; xử lý đặc thù các trang báo Việt Nam (Shadow DOM, custom web components VnExpress, Cloudflare-protected sites).

2.7. Search-Augmented Generation cho fact-checking

Tavily API: web search → evidence retrieval → LLM verdict; kiến trúc RAG cho verification.

2.8. Phát triển tiện ích trình duyệt

Chrome Extension Manifest V3: service worker, content scripts, permissions model; Shadow DOM isolation; Plasmo framework (React + TypeScript + hot reload).

2.9. Tổng kết chương

CHƯƠNG 3. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

3.1. Phân tích yêu cầu

- **Chức năng:** tóm tắt, streaming, fact-check, multi-model switching, evaluation metrics, MoA fusion, human eval admin.
- **Phi chức năng:** latency, scalability, API key security, cross-browser compatibility, cost tracking.

3.2. Kiến trúc hệ thống

Sơ đồ tổng quan 3 service: Extension → Backend API → BERTScore Microservice; giao tiếp REST + SSE; Supabase PostgreSQL làm persistence layer.

- **3.2.1.** Browser Extension (Plasmo): content script inject sidebar, popup, background service worker.
- **3.2.2.** Backend API (Next.js 14 App Router): services layer, Zod validation, multi-provider LLM dispatch.
- **3.2.3.** BERTScore Microservice (FastAPI + Python): vinai/phobert-base; truncate 256 tokens; deployed HF Spaces.

3.3. Module tóm tắt văn bản

- **3.3.1.** Multi-provider LLM abstraction: 14+ models (OpenAI / Gemini / Anthropic / HuggingFace); per-model cost tracking; reasoning model support (o4-mini skip temperature).
- **3.3.2.** Complexity-based routing: token estimation (chars/4); short $\leq 400t$ → ViT5, medium/long → GPT-4o-mini; fallback chain; 3 routing modes (auto / forced / fusion).
- **3.3.3.** Streaming vs batch: SSE token streaming; evaluation metrics fire-and-forget async sau response.

3.4. MoA Output Fusion Pipeline (*đóng góp kỹ thuật chính*)

- **3.4.1.** Thiết kế hai tầng (Wang et al., 2024 Table 1): proposers chạy song song → aggregator tổng hợp.
- **3.4.2.** Proposer layer: gpt-4o-mini + claude-haiku-4-5 + gemini-2.5-flash; parallel execution; timeout handling; failure fallback.

- **3.4.3.** Aggregator layer: gpt-4o; buildAggregatorPrompt — "đánh giá phản biện, tổng hợp, KHÔNG sao chép nguyên văn, trung lập theo phong cách báo chí Việt Nam."
- **3.4.4.** Source article residual connection: original article injected vào aggregator context (Equation 1, MoA paper) để fact-checking grounding — domain adaptation so với paper gốc (instruction-following vs. grounded summarization).
- **3.4.5.** Aggregator prompt engineering: ablation study (baseline / v1-strict-source / v2-soft-source); kết luận: source presence quyết định behavior, không phải wording.

3.5. Module kiểm chứng sự kiện

Pipeline: text → Tavily search (6 results) → LLM claim evaluation → trust score 0–100 + verified flag + sources list.

3.6. Three-Axis Evaluation Framework (*đóng góp phương pháp luận chính*)

- **3.6.1.** Axis A — Content Retention: ROUGE-1/2/L, BLEU, BERTScore, Compression Rate; computed against source article; methodology caveat documented.
- **3.6.2.** Axis B — Quality & Preference: judgeRubric (5 dims) + judgeAbsolute + judgePairwise (position-randomized) + scoreFactuality; runFusionPairwiseJudge; runFusionVsAllDraftsJudge.
- **3.6.3.** Axis C — Human Validation: admin tạo task tại /evaluate/admin (ẩn model name); rater drag-rank tại /evaluate?task=uuid; aggregate Fleiss κ .
- **3.6.4.** Statistical analysis: sign test (two-sided, ties excluded); length-bucketed win rate.
- **3.6.5.** Thiết kế P0-8 (thesis-decisive): so sánh fused vs gpt-4o-alone — loại bỏ capability-gap confound (cả hai đều là gpt-4o output).

3.7. Thiết kế cơ sở dữ liệu

Supabase PostgreSQL; 25 migrations; bảng chính: evaluation_metrics, routing_decisions, moa_fusion_results, moa_draft_results, llm_judge_pairwise, human_eval_tasks, human_eval_responses, app_settings.

3.8. Giao diện người dùng

Extension sidebar (summary + fact-check modal); /metrics page (three-axis view toggle); /evaluate/admin (Create + Review tabs, κ band labels); /evaluate (rater UI tiếng Việt, drag-drop); /settings (model switching + judge config).

3.9. Tổng kết chương

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Thiết lập thực nghiệm

- **4.1.1. Dataset:** 50 bài tienphong.vn; 5 chủ đề $\times$ 10 bài/chủ đề (thời sự, pháp luật, kinh tế, giáo dục, văn hóa); topic-balanced design.
- **4.1.2. Models:** proposers (gpt-4o-mini / claude-haiku-4-5 / gemini-2.5-flash), aggregator (gpt-4o), baseline (gpt-4o đơn lẻ — P0-8 design).
- **4.1.3. Metrics:** Axis A (ROUGE/BLEU/BERTScore/Compression), Axis B (rubric 5-dim / pairwise win rate / factuality entailment %), Axis C (Fleiss κ / avg rank / win rate).
- **4.1.4. Môi trường:** Next.js backend (Vercel), BERTScore microservice (HF Spaces), Supabase cloud; cost toàn bộ thực nghiệm $\approx$ \$1.24.

4.2. Kết quả Axis A — Content Retention

- **4.2.1. Bảng tổng quan:** Fusion (MoA) ROUGE-1=0.421 / ROUGE-L=0.320 / BLEU=0.131 / BERTScore=0.663 — **thắng gpt-4o-alone trên mọi metric Axis A.**
- **4.2.2. Phân tích "nghịch lý MoA":** khi aggregator có source article $\rightarrow$ editorial synthesis thay vì draft-stitching $\rightarrow$ compression cao hơn $\rightarrow$ n-gram overlap tự nhiên cao hơn. Ngược lại khi aggregator không có source, compression giảm, overlap giảm. Overlap metrics trùng phạt đúng hành vi mà paper khuyến khích.
- **4.2.3. Phân tích theo chủ đề.**

4.3. Kết quả Axis B — Quality & Preference

- **4.3.1. Rubric (B.1):** Fusion overall 4.96 > tất cả; gap lớn nhất ở Coverage (+0.16 so với gpt-4o-alone).

- **4.3.2.** Pairwise fused vs gpt-4o-alone (B.2c — THESIS-DECISIVE): **fused 37/48 = 77.1%, p=0.0002**. Capability-gap confound dissolved — cả hai là gpt-4o output.
- **4.3.3.** Pairwise fused vs each proposer (B.2b): fused thắng gpt-4o-mini 98.0% ($p < 0.0001$), claude-haiku-4-5 83.7% ($p < 0.0001$), gemini-2.5-flash 69.6% ($p = 0.0114$). Length-bucketed rates xấp xỉ raw rates → length bias không giải thích kết quả.
- **4.3.4.** Factuality (B.3): claude-haiku 95.5% entailment tốt nhất; gpt-4o-alone 89.9% thấp nhất — xác nhận mode "creative" hơn khi không có MoA framework.

4.4. Kết quả Axis C — Human Validation

(Thiết lập study ≥ 20 tasks, ≥ 2 raters; Fleiss κ ; per-approach preference)

4.5. Cross-axis analysis

Khi 3 trục đồng ý: strong evidence. Khi diverge (Axis A loss nhưng Axis B win): tìm hiểu nguyên nhân — đây là methodological contribution novel nhất.

4.6. Đánh giá routing mechanism

Hiệu quả phân loại độ phức tạp; fallback chain behavior; so sánh auto vs forced mode.

4.7. Đánh giá module kiểm chứng sự kiện

Ví dụ minh họa pipeline Tavily → claim → verdict; phân tích chất lượng search evidence; trust score distribution.

4.8. Thảo luận: giới hạn phương pháp luận

ROUGE/BLEU computed against source article, không phải human-written reference → đo content retention, không đo summary quality. Implication cho các nghiên cứu dùng overlap metrics đánh giá abstractive/fusion summarization.

4.9. Khuyến nghị

Best-draft làm default (rẻ hơn, latency thấp hơn, phù hợp skim-reading). Fusion làm opt-in "editorial mode" khi cần độ chính xác cao hơn.

4.10. Tổng kết chương

KẾT LUẬN

Đóng góp đạt được

1. Hệ thống tiện ích trình duyệt hoàn chỉnh: tóm tắt (streaming + batch) + fact-check + multi-model + admin dashboard.
2. MoA pipeline (Wang et al., 2024) cho tiếng Việt: proposer–aggregator với source residual connection.
3. Three-axis evaluation framework (Axis A/B/C): giải thích tại sao overlap metrics không đủ cho MoA summarization.
4. Kết quả thực nghiệm: fused beats gpt-4o-alone 77.1% ($p=0.0002$); fused beats mọi proposer 69–98% với statistical significance.

Hạn chế

Single-domain dataset (tienphong.vn); LLM-judge là gpt-4o-mini (potential self-preference); Axis C human study quy mô nhỏ; ViT5 routing chưa được eval kỹ với MoA context.

Hướng phát triển

Multi-domain dataset; fine-tune mô hình tiếng Việt chuyên biệt; mở rộng raters Axis C; tích hợp proposer đa dạng hơn (local Vietnamese models); RAG-augmented proposers.

PHỤ LỤC

- A. Ví dụ tóm tắt: bài gốc + drafts (gpt-4o-mini / claude-haiku / gemini-flash) + fused output.
- B. Ví dụ kiểm chứng sự kiện: claims trích xuất, nguồn Tavily, verdict từng claim.
- C. Bảng kết quả đánh giá đầy đủ: ROUGE/BLEU/BERTScore cho 50 bài $\times$ 4 approaches.
- D. Unified three-axis report (output từ `npm run report:unified`).
- E. Aggregator prompt engineering ablation: baseline vs v1-strict vs v2-soft.

F. Hướng dẫn cài đặt: backend, extension, BERTScore service, biến môi trường.

TÀI LIỆU THAM KHẢO

Tiếng Anh

- [1] Dubois, Y., Galambosi, B., Liang, P., and Hashimoto, T. B., "Length-Controlled AlpacaEval: A Simple Way to Debias Automatic Evaluators", *arXiv preprint*, arXiv:2404.04475, 2024.
- [2] Landis, J. R. and Koch, G. G., "The Measurement of Observer Agreement for Categorical Data", *Biometrics*, Vol. 33, 1977, pp. 159-174.
- [3] Li, X., and Liang, P., "Prefix-Tuning: Optimizing Continuous Prompts for Generation", *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2021, pp. 4582-4597.
- [4] Lin, C.-Y., "ROUGE: A Package for Automatic Evaluation of Summaries", *Proceedings of the Workshop on Text Summarization Branches Out (ACL 2004)*, 2004, pp. 74-81.
- [5] Nguyen, C., Nguyen, T., Nguyen, N., and Nguyen, T. H., "ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation", *arXiv preprint*, arXiv:2205.06457, 2022.
- [6] Nguyen, D. Q., Nguyen, T., Nguyen, D. Q., and Phan, D. T., "PhoBERT: Pre-trained language models for Vietnamese", *Findings of EMNLP 2020*, 2020, pp. 1037-1042.
- [7] Phan, L. T., Tran, H., Nguyen, H., and Nguyen, T., "PhoGPT: Generative Pre-training for Vietnamese", *arXiv preprint*, arXiv:2311.02945, 2023.
- [8] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I., "Attention Is All You Need", *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 30, 2017, pp. 5998-6008.
- [9] Wang, J., Wang, X., Wan, Z., Shi, Y., Tang, B., Cheng, H., Liu, X., Yang, X., Chen, W., and Joty, S., "Mixture-of-Agents Enhances Large Language Model Capabilities", *arXiv preprint*, arXiv:2406.04692, 2024.

- [10] Ye, S., Jang, C., Kwak, D., Cho, S., Lee, J., Kim, A., Park, C., Moon, J., Oh, J., and Seo, M., "FLASK: Fine-grained Language Model Evaluation Based on Alignment Skill Sets", *arXiv preprint*, arXiv:2307.10928, 2023.
- [11] Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., and Artzi, Y., "BERTScore: Evaluating Text Generation with BERT", *Proceedings of the 8th International Conference on Learning Representations (ICLR)*, 2020.
- [12] Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., and Stoica, I., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena", *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 36, 2023, pp. 46595-46623.